

Visión por Computador

Práctica 3: Detección de puntos relevantes y Construcción de panoramas

Curso 2019-2020
Cuarto Curso del Grado en Ingeniería
Informática

Contenido

1. Detección de puntos Harris.....	3
Referencias.....	10

1. DETECCIÓN DE PUNTOS HARRIS

El primer ejercicio de esta práctica consiste en detectar puntos estratégicos en una imagen dada por medio del algoritmo de Harris. El algoritmo no se implementa, sino que se utiliza una función de OpenCV.

Para este apartado se han utilizado las imágenes *Yosemite1.jpg* y *Yosemite2.jpg*. Por tanto, en primer lugar, se leen las imágenes en blanco y negro y se llama, con la primera imagen, a una función propia: **Ejercicio1(path, umbral, sigma, incremento, niveles, radio)**, dónde:

- **Path**: es el camino para llegar a la imagen que se quiere estudiar.
- **Umbral**: es un array de valores mínimos permitidos para los puntos máximos de cada escala.
- **Sigma**: sigma inicial de la pirámide Gaussiana.
- **Incremento**: incremento de la sigma de la pirámide Gaussiana.
- **Niveles**: es el número de niveles que se quiere que tenga la pirámide Gaussiana.
- **Radio**: es el número de vecinos que va a tener de distancia mínima un máximo.

Para las imágenes que se van a presentar, se ha creado 4 niveles de la pirámide Gaussiana, número de niveles suficientemente representativos para poder estudiar las diferencias entre ellos, utilizando en el primero un radio de 20 y en el resto de 10 píxeles, y umbrales de 0.001 (nivel inicial), 0.00045 (segundo nivel) y 0.0001 (últimos dos niveles).

En esta función, se crea la pirámide Gaussiana y, para cada nivel conseguido, se calculan los puntos Harris y se pinta, con **cv2.drawKeypoints** (importante incluir el *flag* **cv2.DRAW_MATCHES_FLAGS_DRAW_RICH_KEYPOINTS** para que pinte los puntos a escala con la imagen y las direcciones de los gradientes) los puntos conseguidos.

Para calcular los puntos de cada nivel se implementa una función, **ConseguirKeypoints(imagen, umbral, nivel, radio)** (los parámetros significan lo mismo, a excepción de **imagen** que en este caso es la matriz de píxeles, no el nombre). Los pasos que se realizan son:

1. Calcular los puntos Harris y, a partir de los valores conseguidos, $f = \frac{\lambda_1 \lambda_2}{\lambda_1 + \lambda_2}$.

```
Harris=cv2.cornerEigenValsAndVecs(img, blockSize=5, ksize=3)
# Se eligen esos valores para conseguir bastantes puntos, ya que al
hacer la supresión de no máximos vamos a eliminar muchísimos.
Lamdas = Harris[:, :, :1] # De todos los valores que devuelve, nos quedamos
con las  $\lambda$ .
```

2. Calcular las direcciones de los puntos. Para esto, se le pasa un filtro Gaussiano a la imagen con valor de sigma = 4.5. Una vez se tiene la convolución, se calcula la dirección de cada punto como $\text{dirección} = \frac{dy}{dx}$. Esos valores se pasan a grados para que la función **cv2.drawKeypoints** los acepte.
3. Guardar el radio utilizado, la escala.

4. Hacer la supresión de no máximos. Para esto, se utiliza una ventana auxiliar que irá indicando si el siguiente punto podrá utilizarse o no. Para cada ventana, se elegirá, si se cumplen las condiciones, un punto como máximo.

```
alto, ancho = f.shape[:2]
puntos = np.empty((1,2), dtype=np.int)    # Puntos seleccionados

# Ventana que indica si hay que estudiar o no un punto como posible
# máximo
verificador = np.full((alto, ancho), True, dtype=np.bool)

for i in range (0, alto - radio + 1):
    for j in range (0, ancho - radio + 1):

        # Si ese punto está permitido, se calcula la ventana que tiene
        # ese punto en la esquina superior izquierda
        if verificador[i][j]:
            maximo = -1
            ind = 0
            encontrado = False

            # Se recorre la ventana
            for k in range (0, radio):
                for l in range (0, radio):

                    # Si es un valor permitido y es el mayor de la ventana
                    # y superior al umbral, se guarda
                    if verificador[i+k][j+l] and (f[i+k][j+l] > maximo) and
                    (f[i+k][j+l] > umbral):

                        maximo = f[i+k][j+l]
                        ind = [i+k, j+l]
                        encontrado = True

                    # Todos los valores de la ventana se anulan, ya que
                    # no podrán ser máximos
                    verificador[i+k][j+l] = False

            # En caso de que se encuentre algún punto válido, se guarda
            # en la lista de puntos y se vuelve a activar el punto máximo
            if encontrado:
                verificador[ind[0]][ind[1]] = True
                puntos = np.vstack((puntos,np.array(ind)))
                num_keypoints += 1
```

Con esto, ya tendríamos los puntos Harris detectados en nuestras imágenes. Los resultados conseguidos son los siguientes:

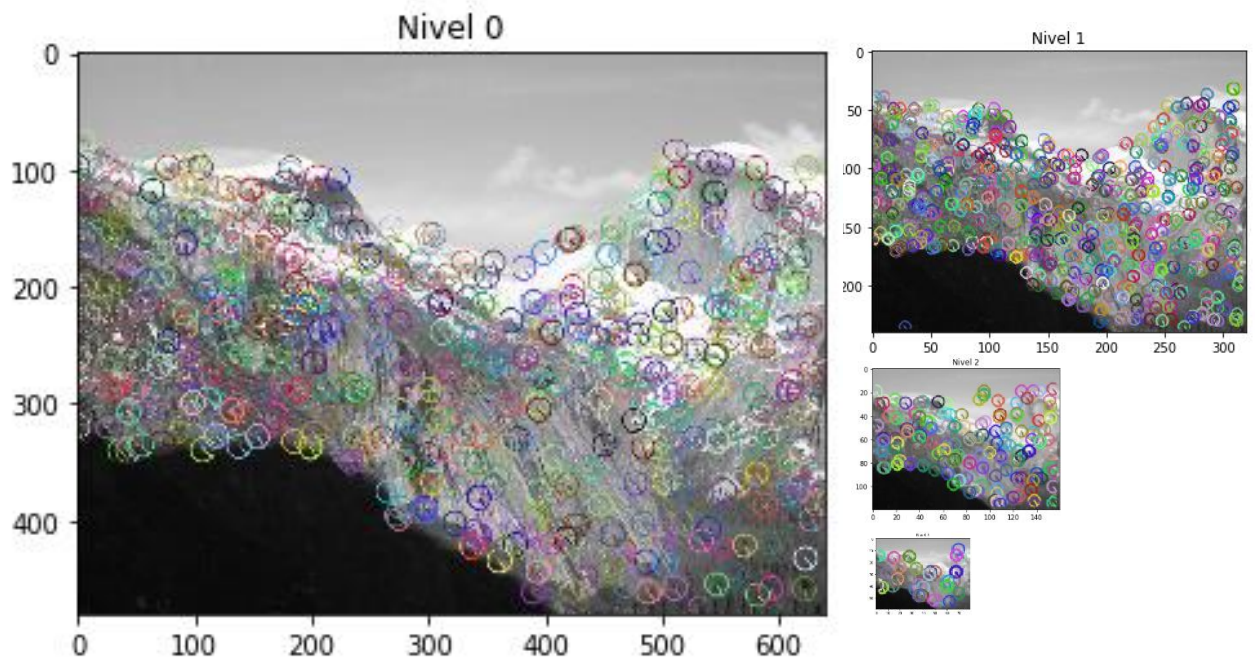
- Fichero *Yosemite1.jpg*:

```
Calculando puntos del nivel 1 ...  
-> Puntos conseguidos: 920  
  
Calculando puntos del nivel 2 ...  
-> Puntos conseguidos: 885  
  
Calculando puntos del nivel 3 ...  
-> Puntos conseguidos: 235  
  
Calculando puntos del nivel 4 ...  
-> Puntos conseguidos: 52  
  
Umbrales: [0.001, 0.00045, 0.0001, 0.001]  
  
Puntos: 2092
```

Lo primero que se observa, antes siquiera de ver las imágenes, es que cuanto más subamos en la pirámide, menos puntos se van a conseguir. Esto es coherente, ya que cuantos más niveles de la pirámide subamos, menos píxeles tenemos.

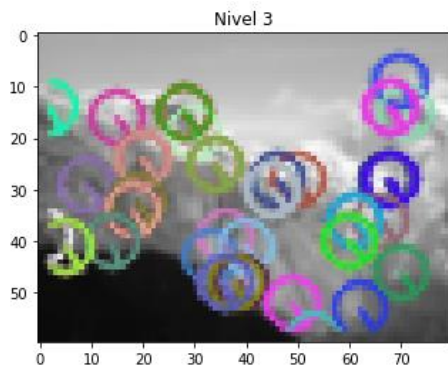
Esos valores de umbrales se obtuvieron en base a ejecuciones de prueba y error. Se fue pintando una a una las imágenes para conseguir un

equilibrio entre la ventana y el umbral. Tras todas esas pruebas, se estimó que el mejor resultado, consiguiendo una gran cantidad de puntos, es la siguiente:



La más pequeña, nivel 4 de la pirámide, es la que tenemos debajo (página siguiente) con más zoom, para poder distinguir mejor los puntos conseguidos. La representación, efectivamente, muestra la cantidad de puntos conseguidos en los pasos anteriores. Al ver la representación podemos hacernos mejor una idea del por qué conseguimos más puntos en las primeras que en las últimas. En la imagen original, se tiene muchísimo detalle, por lo que conseguiremos muchos puntos, relacionados con todos esos detalles.

A medida que vamos subiendo en la pirámide, este detalle se va a ir reduciendo y, a su vez, el tamaño de la imagen. Por esta razón, el número de puntos será menor cuanto más alto sea el nivel de la pirámide.



A diferencia que en la primera imagen, en la que conseguimos 920 puntos, en la del último nivel de pirámide se consiguen 52. En esta es más fácil ver la representación de la dirección del gradiente.

Además del número de datos, podemos ver que en todas las imágenes los puntos se localizan en la misma región: la montaña blanca. Esto nos indica que esta zona será clave para futuras operaciones.

En el caso de los primeros niveles, los puntos están claramente dibujando el área de la montaña. En las otras dos tampoco nos quedamos atrás. Teniendo en cuenta cuanto se ha reducido la imagen, los puntos siguen prácticamente la misma tendencia que en las dos primeras.

Por lo tanto, los puntos en todos los niveles van a ser, *grosso modo*, los mismos. No tienen que ser literalmente los mismos, las mismas coordenadas, pero si la misma zona local de la imagen.

- Fichero Yosemite2.jpg:

```
Calculando puntos del nivel 1 ...
-> Puntos conseguidos: 902

Calculando puntos del nivel 2 ...
-> Puntos conseguidos: 883

Calculando puntos del nivel 3 ...
-> Puntos conseguidos: 257

Calculando puntos del nivel 4 ...
-> Puntos conseguidos: 47

Umbrales: [0.001, 0.00045, 0.0001, 0.001]

Puntos: 2089
```

Con esta imagen comprobamos que los resultados anteriores son coherentes: cuanto más subimos en la pirámide, menos puntos tenemos.

Para este cálculo se han utilizado los mismos parámetros que en el caso anterior.

La representación gráfica que conseguimos es similar a la anterior. Todos los puntos se concentran en todos los niveles en la misma zona de la imagen: la montaña

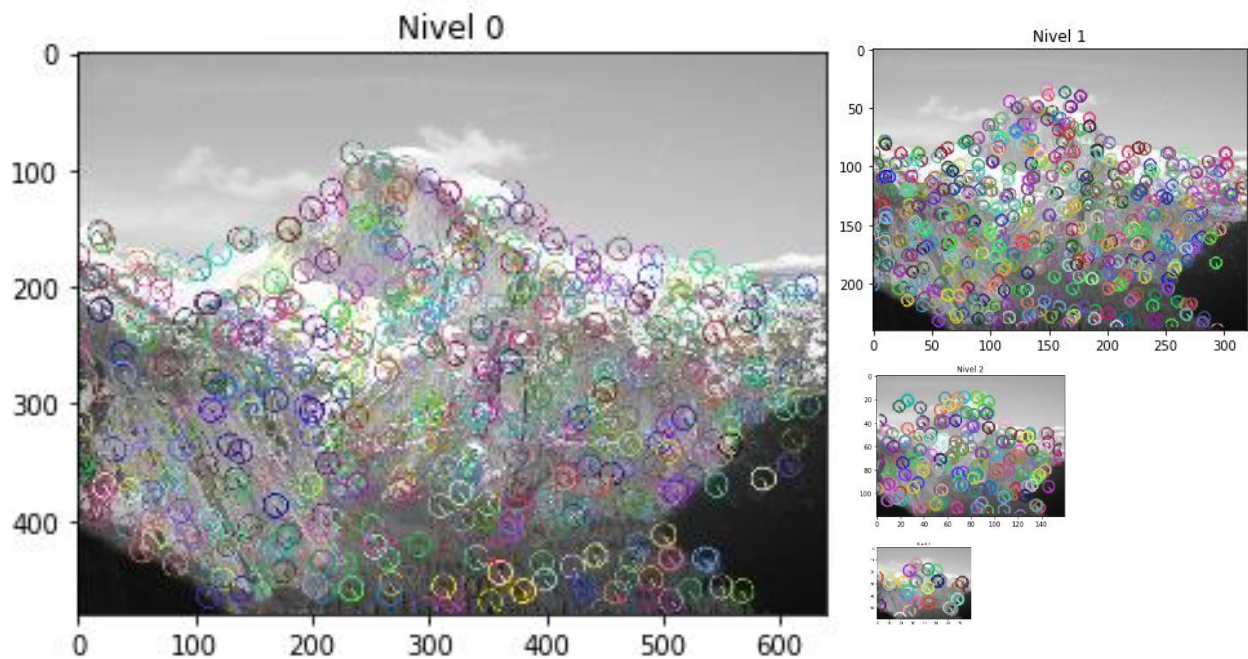


blanca. Además, como añadido a lo comentado con la imagen anterior, podemos ver que la orientación del gradiente es hacia la parte más oscura de la imagen. Es decir, la cumbre la montaña tiene mucha luz y la falda más sombra, la dirección del gradiente va de zonas con más luz a zonas con menos luz, comportamiento correcto.

La representación de todos los niveles de la pirámide está en la página siguiente.

Por tanto, una vez tenemos nuestros puntos y nuestra representación, vamos a calcular las coordenadas subpíxel, con ayuda de la función de OpenCV **cv2.cornerSubPix**, a la que se le pasa la imagen, las coordenadas de los puntos de la imagen que se tienen, el tamaño de ventana

que se va a utilizar (2, 2) y el criterio de parada (en nuestro caso, tras 100 iteraciones o al conseguir una distancia de 0.03).



Para sacar las coordenadas subpíxeles, se implementa una nueva función, **CornerSubPixel** que recibe la imagen y los puntos que se tienen. Esta función hace:

1. Consigue los nuevos puntos, adaptándolos primero al estilo que requiere la función.

```
criteria = (cv2.TERM_CRITERIA_EPS | cv2.TERM_CRITERIA_COUNT, 100, 0.03)
coordenadas = np.empty((len(puntos),1,2), dtype=np.float32)

for i in range (0, len(puntos)):
    coordenadas[i][0][0] = puntos[i].pt[0]
    coordenadas[i][0][1] = puntos[i].pt[1]

cv2.cornerSubPix(img, coordenadas, winSize=(2,2), zeroZone=(-1,-1),
criteria=criteria)
```

2. Se seleccionan 3 puntos aleatorios, que son los que se van a representar.

```
ind = [random.randint(0, len(puntos)),random.randint(0, len(puntos)),
random.randint(0, len(puntos))]

nuevos_puntos = [puntos[ind[0]], puntos[ind[1]], puntos[ind[2]]]

# Este proceso se repite para los 3 puntos
keypoint = cv2.KeyPoint(coordenadas[ind[0]][0][0],
coordenadas[ind[0]][0][1], _size=puntos[ind[0]].size,
_angle=puntos[ind[0]].angle)
nuevas_coordenadas = [keypoint]
```

3. Modificamos el tamaño de la imagen en para quedarnos solo con la zona del punto.

```
for i in range (0, 3):
    x = int(nuevos_puntos[i].pt[1])
    y = int(nuevos_puntos[i].pt[0])

    x = [x-5, x+5]
    y = [y-5, y+5]

    if x[1] < 0:
        x[0] -= x[1]
        x[1] = 0

    if x[0] > img.shape[0]:
        x[1] -= (x[0] - img.shape[0])
        x[0] = img.shape[0]

    # Mismo procedimiento para los valores de y

    original = [nuevos_puntos[i].pt[1]-x[0], nuevos_puntos[i].pt[0]-y[0]]
    corregida = [nuevas_coordenadas[i].pt[1]-x[0],
nuevas_coordenadas[i].pt[0]-y[0]]

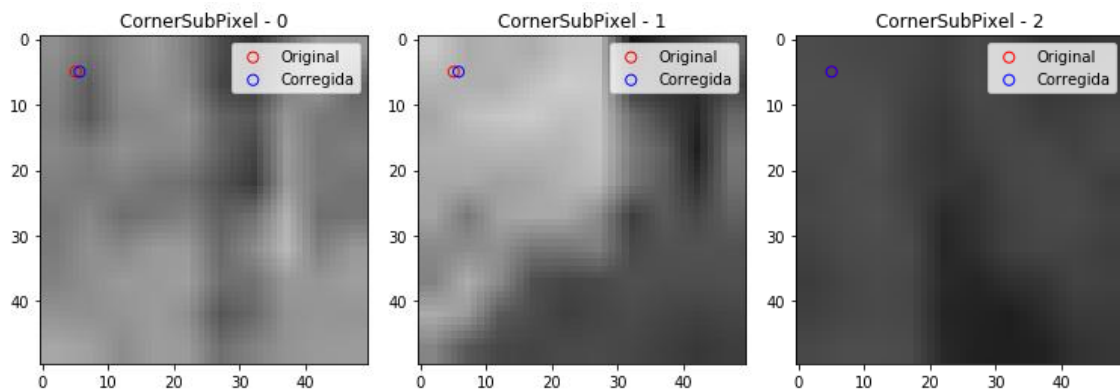
    imagen = img[x[0]:x[1],y[0]:y[1]]
    alto, largo = imagen.shape

    imagen = cv2.resize(imagen, (alto*zoom, largo*zoom))
```


4. Por último, se pintan los dos puntos conseguidos.

Los resultados que se consiguen en este caso son los siguientes:

- Fichero Yosemite1.jpg:



- Fichero *Yosemite2.jpg*:



No en todos los casos hace falta corregir los puntos, como es el caso de las coordenadas 0 y 2 del segundo fichero. En cambio, en otros casos, como el de la coordenada 1, la diferencia entre la coordenada conseguida y la corregida con la coordenadas subpíxeles es grande. En este caso, el punto casi ni tienen área compartida.

Tras haber ejecutado el programa varias veces, se ha comprobado que la probabilidad de que un punto esté mal colocado es mayor que de que esté bien. Suele desplazarse casi siempre.

REFERENCIAS

cv::KeyPoint Class Reference. (21 de Diciembre de 2019). Obtenido de OpenCV:
https://docs.opencv.org/3.4/d2/d29/classcv_1_1KeyPoint.html#acfcc8e0dd1a634a7583686e18d372237

DataCamp. (s.f.). *Python For Data Science Cheat Sheet Numpy*. Obtenido de DataCamp:
https://s3.amazonaws.com/assets.datacamp.com/blog_assets/Numpy_Python_Cheat_Sheet.pdf

Drawing Function of Keypoints and Matches. (26 de Julio de 2019). Obtenido de OpenCV:
https://docs.opencv.org/4.1.1/d4/d5d/group__features2d__draw.html#ga2c2ede79cd5141534ae70a3fd9f324c8

Feature Detection. (19 de Diciembre de 2019). Obtenido de OpenCV:
https://docs.opencv.org/2.4/modules/imgproc/doc/feature_detection.html?highlight=cornersubpix